
Estimation du salaire moyen

à partir des déclarations CNPS

Note méthodologique et corrections apportées aux données

Période couverte : janvier 2024 – novembre 2025 (23 mois)

Cette note décrit le traitement appliqué aux fichiers mensuels de déclarations CNPS, les corrections retenues, et la méthode d'estimation choisie. Elle est rédigée pour être lue sans connaissance préalable du code informatique.

Table des matières

1	Ce que l'on cherche à mesurer, et pourquoi c'est difficile	2
1.1	L'objectif	2
1.2	Le problème central : les salaires manquants ne manquent pas au hasard	2
1.3	Trois régimes de données manquantes	2
2	Les corrections apportées aux données	2
2.1	Filtre 1 — Les doublons stricts	3
2.2	Filtre 2 — Les niveaux de doublon signalés à la source	3
2.3	Filtre 3 — Les doublons d'identifiants	3
2.4	Filtre 4 — Les travailleurs horaires	3
2.5	Filtre 5 — Les salaires implausibles	4
2.6	La conversion au mois, puis l'écèlement des valeurs extrêmes	4
3	La méthode d'estimation retenue	5
3.1	Deux niveaux de non-déclaration, et non un seul	5
3.2	Ce que les données ont montré	5
3.3	Le principe de la correction par repondération	6
3.4	Qualité des modèles obtenue	6
3.5	L'imputation des entreprises totalement muettes	6
4	Point de vigilance non résolu	7
4.1	La concentration des poids	7
4.2	Portée et options	7
5	Limites à signaler	7
6	Synthèse	8

1 Ce que l'on cherche à mesurer, et pourquoi c'est difficile

1.1 L'objectif

Nous voulons estimer le salaire moyen des travailleurs déclarés à la CNPS, et le décliner par sexe, secteur d'activité, commune, taille d'entreprise, profession et tranche d'âge.

À première vue, l'affaire semble simple : les fichiers contiennent des salaires, il suffirait d'en faire la moyenne. C'est précisément cette intuition qu'il faut écarter, et la raison en est le cœur de cette note.

1.2 Le problème central : les salaires manquants ne manquent pas au hasard

Sur l'ensemble des lignes retenues après nettoyage, un peu plus de quatre sur dix seulement portent un salaire exploitable. Près de six lignes sur dix n'indiquent aucun salaire.

Si ces absences étaient réparties au hasard, il n'y aurait pas de difficulté : la moyenne calculée sur les 43 % observés serait une estimation correcte de la moyenne générale. C'est le raisonnement du sondage classique — interroger 1 000 personnes tirées au sort renseigne sur la population entière.

Mais ces absences ne sont pas aléatoires. Une entreprise qui ne déclare pas n'est pas une entreprise ordinaire : elle est plus souvent petite, plus souvent dans certains secteurs, et surtout elle verse probablement des salaires différents de celles qui déclarent scrupuleusement.

L'analogie du sondage biaisé

Supposons que l'on veuille connaître la taille moyenne des habitants d'une ville, et que l'on installe le mètre à l'entrée d'un club de basket. On obtiendra une moyenne parfaitement calculée — et parfaitement fausse. L'erreur ne vient pas du calcul mais de *qui a été mesuré*. Notre situation est analogue : les salaires observés ne sont pas un échantillon neutre des salaires versés. Ignorer ce point produirait un chiffre précis et biaisé.

1.3 Trois régimes de données manquantes

La statistique distingue trois situations, qui appellent des traitements différents.

- **Manquant complètement au hasard.** L'absence ne dépend de rien. Une page perdue, une saisie oubliée sans motif. On peut alors ignorer les manquants sans biais.
- **Manquant conditionnellement au hasard.** L'absence dépend de caractéristiques que l'on observe — le secteur, la taille de l'entreprise, son historique. C'est le cas exploitable : si l'on sait *qui* a tendance à ne pas déclarer, on peut corriger.
- **Manquant de façon non aléatoire.** L'absence dépend du salaire lui-même, y compris à caractéristiques observées identiques. Aucune correction n'est pleinement satisfaisante ; on documente et l'on teste la sensibilité.

Notre traitement se place dans le deuxième régime, et nous verrons plus loin que les données le justifient : la non-déclaration est très fortement prédictible à partir des caractéristiques observables.

2 Les corrections apportées aux données

Avant toute estimation, les fichiers bruts subissent une série de filtres. Chacun répond à un problème identifié, et chacun est chiffré : nous savons exactement combien de lignes sont écartées et pourquoi.

Le point de départ est de 27 558 243 lignes réparties sur 23 fichiers mensuels.

Les volumes indiqués ci-après pour chaque filtre correspondent à l'exécution de référence. L'assouplissement du filtre 2, décrit plus bas, augmente sensiblement le volume conservé : les chiffres définitifs sont ceux du journal d'exécution le plus récent.

2.1 Filtre 1 — Les doublons stricts

Des lignes rigoureusement identiques sur toutes les colonnes apparaissent dans les fichiers. Elles traduisent une double saisie et non deux emplois. Retrait : 421 lignes (0,00 %).

2.2 Filtre 2 — Les niveaux de doublon signalés à la source

Les fichiers sources portent une colonne de qualité qui signale les enregistrements ambigus. La répartition observée est la suivante :

Marquage	Lignes	Traitement
unique	22 661 333	conservé
doublon niveau 2	2 276 897	conservé
doublon niveau 4	2 243 703	conservé
doublon niveau 1	362 329	conservé
doublon niveau 3	13 560	retiré

Seul le **niveau 3** est écarté, soit 13 560 lignes (0,06 %). Les niveaux 1, 2 et 4 sont conservés.

Ce choix mérite d'être explicité, car il a été révisé. Une première version du traitement ne retenait que les lignes marquées *unique*, ce qui revenait à écarter 4 896 489 lignes — près d'une sur cinq. Or un marquage de doublon ne signifie pas nécessairement double compte : deux lignes peuvent légitimement correspondre à un cumul d'emplois chez des employeurs distincts, ou à une reprise de contrat en cours de mois. Les écarter en bloc revenait à perdre des situations réelles.

La protection contre les doubles comptes est donc reportée sur le filtre suivant, qui agit sur une base vérifiable : un même individu, chez un même employeur, sur un même mois.

Principe. Un signalement produit en amont indique un doute, pas un verdict. On ne retire une ligne que sur un critère que l'on peut vérifier soi-même — ici, l'identité du triplet individu / employeur / mois.

2.3 Filtre 3 — Les doublons d'identifiants

Ce filtre porte l'essentiel de la protection contre les doubles comptes, depuis que le filtre précédent a été assoupli.

La règle est vérifiable directement : une même personne ne peut avoir qu'une seule déclaration chez un même employeur pour un même mois. Lorsque plusieurs lignes correspondent à ce triplet, une seule est retenue — celle au salaire le plus élevé, les autres étant le plus souvent des saisies incomplètes.

Un point mérite attention : ce filtre ne touche *pas* les personnes déclarées chez plusieurs employeurs différents. Le cumul d'emplois est une réalité, non une erreur, et l'écraser sous-estimerait les revenus.

2.4 Filtre 4 — Les travailleurs horaires

Les fichiers distinguent trois périodicités de rémunération : mensuelle, journalière, horaire. Le salaire déclaré n'a donc pas la même unité selon les lignes, et il faut le ramener à une base mensuelle commune.

Périodicité	Lignes	Part
Non renseignée	12 743 340	56,2 %
Mensuelle	9 265 833	40,9 %
Journalière	525 750	2,3 %
Horaire	126 410	0,6 %

L’audit des durées travaillées a révélé une anomalie décisive : **près de 7 lignes horaires sur 10 portent une durée matériellement impossible** (supérieure à 744 heures, soit le nombre d’heures que compte un mois complet, nuits comprises). Chez les journaliers, la même anomalie ne concerne que 0,12 % des lignes.

La conclusion s’impose : le champ *horaire* n’est pas fiable. Il est vraisemblablement utilisé comme valeur par défaut lors de saisies incertaines. Ces 126 410 lignes sont écartées (0,6 % du volume).

Les journaliers, eux, sont *conservés* et convertis au mois par un coefficient de **22,4 jours ouvrés**. Les écarter aurait retiré une population réelle sur la foi d’un problème qui ne la concerne pas.

Le choix de 22,4 mérite un mot. Ce nombre correspond à la moyenne annuelle des jours travaillés une fois déduits les dimanches et les jours fériés. La convention alternative, 26 jours, suppose un mois travaillé six jours sur sept sans interruption — une hypothèse qui majore mécaniquement les salaires reconstitués. À 22,4, une rémunération de 3 000 FCFA par jour équivaut à 67 200 FCFA par mois, contre 78 000 FCFA avec l’ancienne convention.

Ce coefficient sert aussi à définir le seuil de plausibilité applicable aux journaliers : le salaire minimum mensuel divisé par 22,4, soit 3 348 FCFA par jour. Les deux usages restent ainsi cohérents — un journalier payé exactement au seuil atteint exactement le minimum une fois converti.

À retenir. Nous n’excluons pas une catégorie parce qu’elle est gênante, mais parce que la mesure a démontré qu’elle n’est pas exploitable. Les journaliers, dont les durées sont cohérentes, restent dans le champ.

2.5 Filtre 5 — Les salaires implausibles

Un salaire nul, négatif, ou inférieur au minimum légal traduit une erreur de saisie plutôt qu’une rémunération réelle. Le seuil est appliqué *par périodicité* : 75 000 FCFA pour un mensuel, mais 3 348 FCFA pour une journée — soit le même minimum, exprimé dans l’unité de la ligne.

Ce détail a son importance. Appliquer le seuil mensuel à un salaire journalier aurait éliminé la quasi-totalité des journaliers : un montant de quelques milliers de francs par jour est parfaitement normal, il est seulement exprimé dans une autre unité.

Les salaires manquants ne sont pas retirés à ce stade : leur absence est précisément l’information que la méthode va traiter.

2.6 La conversion au mois, puis l’écèlement des valeurs extrêmes

Une fois les filtres passés, les salaires journaliers sont multipliés par 26 pour obtenir un équivalent mensuel (517 248 lignes concernées).

Vient ensuite l’**écèlement** des valeurs extrêmes, aussi appelé *winsorisation*. Le principe : une poignée de valeurs aberrantes peut déplacer une moyenne de façon disproportionnée. Plutôt que de supprimer ces lignes — ce qui perdrait l’information qu’un salaire existe — on ramène les 1 % les plus bas et les 1 % les plus hauts aux valeurs seuils correspondantes.

Pourquoi l'ordre des opérations change tout

L'écèlement était initialement appliqué *avant* la conversion des périodicités. Le seuil bas calculé sur ce mélange d'unités valait 510 FCFA — une valeur qui n'est ni un salaire mensuel plausible ni un taux journalier identifiable. Résultat : le garde-fou ne coupait rien du côté des mensuels.

Après correction de l'ordre, le seuil bas s'établit à 75 000 FCFA et le seuil haut à 5 303 714 FCFA. Ce sont des bornes interprétables. On observe **zéro valeur écelée en bas** — signe que les filtres précédents ont déjà fait leur travail — et 96 290 en haut.

Une opération statistiquement correcte appliquée dans le mauvais ordre devient inopérante. Le contrôle ne consiste pas seulement à vérifier qu'un traitement a lieu, mais qu'il produit des bornes qui ont un sens.

3 La méthode d'estimation retenue

3.1 Deux niveaux de non-déclaration, et non un seul

La note méthodologique de référence propose deux approches. La différence tient à une question simple : *où* se situe la non-déclaration ?

- **Approche à un étage.** On suppose qu'une entreprise déclare ou ne déclare pas. Si elle déclare, tous ses salariés sont couverts.
- **Approche à deux étages.** Une entreprise peut déclarer *partiellement* : transmettre un état pour une partie seulement de ses effectifs.

Le choix entre les deux n'est pas affaire de préférence. Il se tranche par la mesure : les déclarations partielles existent-elles, et dans quelle proportion ?

3.2 Ce que les données ont montré

Nous avons classé chacun des 1 442 146 couples *entreprise × mois* en trois catégories.

Situation	Couples	Part
Aucune déclaration	865 524	60,0 %
Déclaration complète	357 551	24,8 %
Déclaration partielle	219 071	15,2 %

Les déclarations partielles représentent 15,2 % des couples — une minorité en apparence. Mais ces entreprises sont nettement plus grandes que la moyenne. Rapporté aux salariés concernés, le constat change d'échelle :

Le chiffre décisif

65,3 % des salaires manquants — soit 10 133 921 lignes sur 15 519 029 — se trouvent dans des entreprises qui *ont bien déclaré ce mois-là*, mais sans couvrir la totalité de leur effectif. Une méthode à un seul étage considérerait ces entreprises comme *non déclarantes* et n'appliquerait aucune correction à ces lignes. Près des deux tiers du problème resteraient non traités.

C'est ce résultat, et lui seul, qui a déterminé le choix de l'approche à deux étages.

3.3 Le principe de la correction par repondération

L'idée est celle du redressement d'enquête. Reprenons l'analogie du sondage.

Si dans une enquête les femmes répondent deux fois moins souvent que les hommes, on ne jette pas les réponses des femmes : on leur donne un *poids* double, pour que chaque répondante représente les deux femmes qu'elle incarne dans la population.

Notre correction procède ainsi. Pour chaque ligne, on estime la probabilité qu'elle soit déclarée, à partir des caractéristiques observables. Puis on attribue un poids inversement proportionnel à cette probabilité :

$$\text{poids} = \frac{1}{\text{probabilité d'être déclaré}}$$

Une déclaration rare, provenant d'un profil qui déclare peu, compte davantage : elle représente tous ses semblables restés silencieux.

Avec deux étages, la probabilité totale se décompose en un produit :

$$\underbrace{\pi}_{\text{probabilité d'être déclaré}} = \underbrace{p}_{\text{l'entreprise déclare}} \times \underbrace{q}_{\text{le salarié est couvert, sachant qu'elle déclare}}$$

Deux modèles sont donc estimés : l'un sur les entreprises, l'autre sur les individus au sein des entreprises déclarantes.

3.4 Qualité des modèles obtenue

La capacité d'un modèle à distinguer les déclarants des non-déclarants se mesure par un indicateur compris entre 0,5 (hasard pur) et 1 (discrimination parfaite). Le seuil d'acceptabilité retenu est 0,60.

Modèle	Indicateur	Lecture
Déclaration de l'entreprise	0,9246	très discriminant
Couverture du salarié	0,9713	très discriminant

Ces valeurs élevées confirment le diagnostic posé en première partie : la non-déclaration est *fortement liée aux caractéristiques observables*. Ce n'est pas un phénomène aléatoire, et c'est précisément ce qui rend la correction légitime.

Une précision utile : ces modèles n'utilisent que des informations antérieures au mois considéré. Un modèle qui n'aurait le mois courant obtiendrait un score parfait sans rien prédire du tout. Un premier ajustement donnait d'ailleurs un score de 1,0000 — signal d'alerte classique, corrigé depuis.

3.5 L'imputation des entreprises totalement muettes

Pour les 865 524 couples sans aucune déclaration, la repondération ne suffit pas : il n'y a rien à repondérer. Un salaire moyen est donc *imputé* à partir des caractéristiques de l'entreprise et de son historique.

Cette imputation est répétée cinq fois avec une part d'aléa. La raison est d'honnêteté statistique : une valeur imputée n'est pas une valeur observée, et présenter une estimation unique reviendrait à masquer l'incertitude. En combinant cinq versions, les intervalles de confiance publiés intègrent le fait qu'une partie du chiffre est reconstituée.

4 Point de vigilance non résolu

4.1 La concentration des poids

Un problème demeure, et il doit être porté à connaissance avant toute utilisation des chiffres. Les poids attribués aux entreprises sont très inégalement répartis :

Statistique	Valeur
Poids médian	2,77
Poids moyen	1 492.73
Poids maximal	8 231.55

Un écart de cette ampleur entre médiane et moyenne signale une concentration extrême : **environ 1 % des couples entreprise × mois portent une part majeure de l'estimation.**

L'explication tient à la qualité même des modèles. Lorsqu'une entreprise n'a jamais déclaré, le modèle lui attribue une probabilité de déclaration très proche de zéro. L'inverse de cette probabilité devient alors considérable. La méthode fonctionne n trop bien z : elle identifie si sûrement les non-déclarants qu'elle produit des poids déséquilibrés.

4.2 Portée et options

Concrètement, l'estimation repose sur un petit nombre d'entreprises. Si l'une d'elles présente une particularité, elle se répercute fortement sur le résultat d'ensemble. L'estimation reste correcte en moyenne, mais sa *stabilité* est affaiblie.

Deux voies sont possibles :

Resserrer le plafond des poids	Retirer l'historique du modèle
Limiter les poids au 95^e centile au lieu du 99^e. Réduit la concentration immédiatement. <i>Traite l'effet.</i> Simple, réversible, effet mesurable.	L'historique de déclaration prédit presque parfaitement le silence. L'écart donne des probabilités moins extrêmes. <i>Traite la cause.</i> Plus rigoureux, mais dégrade le pouvoir explicatif.

Recommandation

Ce point doit être arbitré **avant** diffusion des résultats. En l'état, les chiffres par grandes catégories (national, sexe, grands secteurs) sont exploitables ; les ventilations fines — notamment par profession, qui compte 20 656 modalités — appellent la plus grande prudence.

5 Limites à signaler

Trois réserves accompagnent ces résultats.

Deux variables entièrement vides. Le niveau d'étude et la catégorie d'entreprise sont absents à 100 %. Aucune ventilation selon ces axes n'est possible, et ils ne peuvent servir au modèle.

La périodicité inconnue dans 56,9 % des cas. Ces lignes sont traitées comme mensuelles par défaut. Cette hypothèse est raisonnable — c'est la modalité dominante parmi les lignes renseignées — mais elle demeure une hypothèse. Si une part significative de ces lignes correspondait en réalité à des journaliers, les salaires concernés seraient sous-estimés.

Les indicateurs d'inégalité sont à écarter. L'écrêtement des valeurs extrêmes, nécessaire pour stabiliser les moyennes, comprime mécaniquement le haut de la distribution. Tout indicateur de dispersion ou de concentration calculé sur ces données serait biaisé vers le bas. Les moyennes et médianes restent valides.

6 Synthèse

Décision	Fondement mesuré
Exclure les travailleurs horaires	69 % de durées matériellement impossibles, contre 0,12 % chez les journaliers
Conserver les journaliers, convertis au mois	Durées cohérentes ; les exclure retirerait une population réelle
Convertir les journaliers à 22,4 jours et non 26	22,4 est la moyenne annuelle hors dimanches et jours fériés ; 26 suppose six jours travaillés sur sept
Ne retirer que le niveau 3 des doublons signalés	Un signalement amont indique un doute ; la déduplication vérifiable (individu / employeur / mois) prend le relais
Retenir l'approche à deux étages	65,3 % des salaires manquants sont en entreprise déclarante
Écrêter après conversion des périodicités	Avant conversion, le seuil bas (510 FCFA) ne coupait rien
Imputer cinq fois plutôt qu'une	Les intervalles publiés doivent refléter l'incertitude d'imputation

Les lignes écartées le sont sur des motifs documentés et chiffrés, chacun vérifiable dans le journal d'exécution. Le filtre le plus lourd n'est plus le marquage produit en amont — assoupli au seul niveau 3 — mais la déduplication sur le triplet individu / employeur / mois, dont la règle peut être contrôlée directement sur les données.

La chaîne s'exécute intégralement et les deux modèles de correction atteignent une qualité largement supérieure au seuil requis. Le point de vigilance sur la concentration des poids reste à arbitrer avant diffusion.