
Note méthodologique

Traitement des déclarations salariales

CNPS

Pipeline Python v2 corrigé

Unité : salarié-employeur-mois

Méthode : pondération IPW à deux étages

Statut : estimations ponctuelles, inférence F.1 en attente

Avertissement de diffusion

Cette version ne revendique aucun intervalle de confiance. Les valeurs réelles n'ont pas été recalculées pendant l'audit hors VPN. Toute diffusion doit être rattachée à une session MinIO, à une période, à une empreinte de configuration et aux contrôles décrits dans cette note.

Table des matières

1	Objet et portée	2
2	Préparation des données	2
2.1	Types, dates et montants	2
2.2	Déduplication	2
2.3	Périodicité salariale	2
3	Panel entreprise et champ à risque	2
3.1	Réponse de l'employeur	2
3.2	Bornes et absence de registre de cessation	3
3.3	Fenêtre glissante	3
3.4	Information disponible à date	3
4	Modèles de réponse	3
4.1	Premier étage	3
4.2	Second étage	3
4.3	Diagnostics	3
5	Pondération et statistiques	4
5.1	Poids final	4
5.2	Estimateurs	4
6	Inférence et statut des intervalles	4
7	Secret statistique	4
8	Validation, export et filiation	5
9	Contrôles avant diffusion	5
10	Limites ouvertes	5
	Références	5

1 Objet et portée

Le pipeline transforme les déclarations mensuelles de la CNPS en indicateurs de distribution salariale. L'unité d'analyse est le couple **salarié–employeur–mois**. Une personne employée chez deux employeurs le même mois forme deux unités légitimes. Dans un tableau cumulé, une personne présente plusieurs mois contribue plusieurs fois : le tableau décrit des mois d'emploi, non un stock de personnes uniques.

Estimand

La cible est la distribution des salaires des unités salarié–employeur–mois représentables par les employeurs présents dans les fichiers sources et entrant dans le champ à risque du mois considéré.

Sont hors champ : les employeurs absents de tout le panel, les salariés dont aucune ligne n'existe dans aucune source, et les rémunérations non représentées par une ligne salarié exploitable. Les résultats ne sont donc pas une mesure exhaustive de l'emploi ou de la masse salariale de toute l'économie ivoirienne.

2 Préparation des données

2.1 Types, dates et montants

Le parseur reconnaît les formats numériques français et internationaux. Le taux d'échec de conversion est journalisé et bloque l'étape au-delà du seuil configuré. Les âges et anciennetés sont calculés au dernier jour du mois de déclaration. Ils ne dépendent jamais de la date d'exécution.

2.2 Déduplication

Les doublons stricts sont retirés. Pour une clé complète (individu, employeur, période), la ligne de salaire le plus élevé est conservée. Les cumuls d'emplois auprès d'employeurs différents sont préservés. Une clé incomplète n'est jamais dédoublée : elle est conservée avec un indicateur explicite de clé de déduplication incomplète.

2.3 Périodicité salariale

La variable `SALAIRE_BRUT_ESTIME_AU_MOIS` applique les conventions suivantes : montant mensuel inchangé, taux journalier multiplié par 22,4, taux horaire multiplié par 179,2. Une périodicité inconnue est traitée comme mensuelle par défaut ; l'hypothèse peut être remplacée par `daily` dans une analyse de sensibilité.

Le seuil salarial est appliqué dans une unité cohérente avec cette périodicité. Le volume de périodicités inconnues et le nombre de lignes qu'elles font exclure sont journalisés. La colonne suffixée `_W` est winsorisée après la conversion. La colonne sans suffixe reste non winsorisée.

3 Panel entreprise et champ à risque

3.1 Réponse de l'employeur

$$D_{jt} = \mathbf{1}\{\text{au moins un salaire positif est déclaré par } j \text{ au mois } t\}.$$

Un état $D_{jt} = 1$ avec salaire moyen non positif, manquant ou non fini est considéré impossible et provoque un échec.

3.2 Bornes et absence de registre de cessation

Le panel commence au mois d'immatriculation, ou à la première apparition si la date manque. La troncature gauche et le début imputé sont marqués. Aucune cessation n'est déduite de la dernière déclaration : faute de registre de radiation, toutes les entreprises sont prolongées jusqu'à la fin commune du panel et leur fin est dite censurée.

3.3 Fenêtre glissante

Pour le mois t , une entreprise est dans le champ si elle a déclaré au moins une fois pendant les K mois **strictement précédents**. La valeur par défaut est $K = 12$. Le mois courant n'entre pas dans le champ, afin de ne pas faire dépendre l'univers de la réponse que le modèle doit expliquer.

Les mois d'amorce avec moins de K mois disponibles sont marqués comme fenêtre extensible. Une diffusion doit comparer $K \in \{6, 12, 24, \infty\}$.

3.4 Information disponible à date

Secteur, commune et taille sont propagés uniquement depuis la dernière valeur antérieure connue. L'âge de l'entreprise est recalculé à chaque mois. Les indicateurs $\acute{n}$ jamais observé auparavant $\acute{z}$ distinguent une information absente d'une modalité économique réelle. Aucune valeur future n'est rétropropagée.

4 Modèles de réponse

4.1 Premier étage

Une régression logistique pénalisée L2 estime

$$p_{jt} = \Pr(D_{jt} = 1 \mid X_{jt}).$$

Les covariables incluent les attributs disponibles à date, la réponse du mois précédent, le taux de réponse passé et les indicateurs d'amorce.

4.2 Second étage

Pour une ligne salarié existante chez un employeur déclarant,

$$S_{ijt} = \mathbf{1}\{Y_{ijt} > 0\}, \quad q_{ijt} = \Pr(S_{ijt} = 1 \mid D_{jt} = 1, X_{ijt}, Z_{jt}).$$

L'historique est calculé par couple individu-employeur. Un lag n'est qualifié de mois précédent que pour un écart calendaire égal à un. La complétude de l'entreprise vient du panel entreprise, est décalée d'un mois civil, puis attribuée identiquement à toutes les lignes du même couple entreprise-mois.

Limite du second étage

Le modèle q traite un salaire manquant sur une ligne existante. Il ne peut pas corriger le salarié dont la ligne entière est absente, faute de registre exhaustif salarié-employeur-mois.

4.3 Diagnostics

Les prédictions sont hors échantillon, avec plis groupés par employeur. Sont contrôlés : classe cible, finitude, recouvrement des propensions, calibration-in-the-large, pente de calibration, score de Brier, équilibre des covariables, clipping et trimming. Une strate structurellement jamais répondante est une violation de positivité.

L'AUC reste descriptive. Une AUC de 0,5 peut être correcte sous MCAR ; une AUC élevée ne garantit pas le recouvrement. Les modèles sont sauvegardés en résumés JSON non exécutables, jamais en pickle distant.

5 Pondération et statistiques

5.1 Poids final

$$R_{ijt} = D_{jt}S_{ijt}, \quad w_{ijt}^{\text{brut}} = \frac{R_{ijt}}{\hat{p}_{jt}\hat{q}_{ijt}}.$$

Le produit positif est tronqué aux quantiles configurés. Les non-répondants et les lignes hors champ portent un poids nul. Le poids n'est pas stabilisé : il n'a pas de probabilité marginale au numérateur. Il n'est pas normalisé à moyenne un. Aucun n effectif pondéré z n'est publié en l'absence de calibration sur un total de population.

5.2 Estimateurs

La moyenne est l'estimateur ratio de Hájek :

$$\hat{\mu} = \frac{\sum_i w_i Y_i}{\sum_i w_i}.$$

La variance diffusée est une dispersion descriptive pondérée avec correction de Kish ; ce n'est pas la variance de $\hat{\mu}$. Les quantiles utilisent la fonction de répartition centrée

$$F_i = \frac{\sum_{k \leq i} w_k - w_i/2}{\sum_k w_k}.$$

Le Gini est pondéré. Les minimum et maximum sont des extrêmes observés.

La moyenne et la variance descriptive utilisent le salaire winsorisé. Les quantiles, le Gini et les extrêmes utilisent le salaire non winsorisé. Des séries mensuelles sont publiées pour le national, le secteur, le sexe et la taille réduite ; les ventilations fines sont libellées n cumul sur la période z .

6 Inférence et statut des intervalles

Les déclarations sont traitées comme une population finie affectée par la non-réponse. Un bootstrap naïf d'employeurs ajouterait une variance de tirage qui ne correspond pas à ce cadre. L'incertitude vient notamment de l'estimation conjointe de p et q , de leur covariance au niveau employeur et des non-linéarités des estimateurs.

Cette variance n'est pas encore spécifiée de manière complète. La configuration impose donc `point_only` ; chaque sortie porte `POINT_ONLY_F1_PENDING` ; toute colonne d'intervalle ou d'erreur-type est rejetée. L'imputation multiple, Rubin, l'AIPW et la double robustesse sont hors du chemin de publication.

7 Secret statistique

Une cellule entière est supprimée si elle contient moins de 30 individus distincts contributeurs, moins de 3 employeurs distincts, ou si un employeur représente plus de 85% de la masse salariale observée non pondérée. Les identifiants nuls ne comptent pas. Un contributeur a un salaire positif fini et un poids final positif.

Si une seule cellule est supprimée dans une marge additive, la plus petite cellule publiée de cette même marge est supprimée en secondaire. Pour les tableaux mensuels croisés, la règle est appliquée mois par mois. Ces seuils restent subordonnés à toute doctrine officielle ANStat/CNPS plus stricte.

8 Validation, export et filiation

L’export n’est autorisé que si la validation des données, des modèles, des poids et des cellules passe sans erreur. Le Gini conserve trois décimales dans Excel ; les valeurs nulles ou non finies sont remplacées par un tiret.

Chaque session reçoit un UUID. Son manifeste contient l’empreinte SHA-256 de la configuration sans secrets, le commit et l’état sale Git, les versions des dépendances, les durées et sorties déclarées. Les objets canoniques MinIO sont encore réécrits en place : la réplication historique complète exige leur versionnement immuable par session.

9 Contrôles avant diffusion

Domaine	Contrôle obligatoire
Données	Schéma, parse numérique, clés incomplètes, doublons, périodicité, volumes avant/après filtre.
Temps	Mois continus, âges à date, aucune covariable future, sensibilité K .
Réponse	Taux D et S , support p/q , calibration, Brier, équilibre, clipping et trimming.
Poids	Identité $R/(pq)$, poids nuls hors réponse, distribution et extrêmes.
Publication	Variables par statistique, séries mensuelles, secret primaire et secondaire, aucun intervalle F.1.
Comparabilité	Pont CIAP versionné, couverture CNPS, rapprochement avec la rémunération des salariés des comptes nationaux à concepts constants.

10 Limites ouvertes

1. variance F.1 et validation de couverture sur processus générateurs ;
2. absence de registre de cessation ;
3. absence de panel salarié exhaustif pour les lignes entièrement omises ;
4. seuils de confidentialité à faire valider institutionnellement ;
5. objets MinIO canoniques non immuables ;
6. table de passage CIAP–NAPCN à obtenir et versionner officiellement.

Les tests synthétiques valident la logique hors ligne. Ils ne remplacent pas le recalcul des valeurs réelles, des sensibilités et des rapprochements externes une fois l’accès VPN/MinIO rétabli.

Références

Hájek, J. (1971) ; Kish, L. (1965) ; Lerman, R. I. et Yitzhaki, S. (1989) ; Lumley, T. (2010) ; Wooldridge, J. M. (2007).